

DCC011: INTRODUÇÃO A BANCO DE DADOS - TRABALHO PRÁTICO 2 – 10 PONTOS

INTRODUÇÃO:

O objetivo deste trabalho é projetar e implementar um banco de dados relacional para análise de dados abertos governamentais. O projeto do banco de dados deverá seguir um processo *bottom-up*, iniciado a partir da análise de um conjunto de dados existente, passando pela normalização de seu esquema relacional, e mapeamento do esquema relacional normalizado para o esquema ER correspondente. O conjunto de dados reais escolhido deverá ser então inserido no banco de dados normalizado. Por fim, consultas analíticas deverão ser formuladas e executadas sobre esse banco de dados.

Características básicas (até 40%): Para definição do tema, cada grupo deverá escolher um conjunto de dados **atualizado em 2025** no portal dados.gov.br/dados/conjuntos-dados.¹ Para o conjunto de dados escolhido, deverão ser apresentados o **esquema relacional normalizado** e o **diagrama ER** correspondentes, atendendo aos seguintes requisitos:

- Pelo menos 4 tipos de entidade, cada tipo com ao menos 2 atributos (além de um atributo identificador);
- Pelo menos 3 tipos de relacionamento, ao menos 1 com cardinalidade M:N;
- Pode ser necessário alterar os dados originais para atender a esses requisitos.

Consultas (até 40%): Deverão ser especificadas e executadas um total de **10 consultas em SQL**, sendo:

- 2 consultas envolvendo as operações de seleção e projeção;
- 3 consultas envolvendo a junção de duas relações;
- 3 consultas envolvendo a junção de três ou mais relações;
- 2 consultas envolvendo funções de agregação sobre o resultado da junção de pelo menos duas relações.

Análise dos resultados (até 20%): Além dos requisitos listados acima, os relatórios produzidos serão avaliados quanto à criatividade e profundidade das análises desenvolvidas a partir dos resultados retornados pelas várias consultas.

Aplicação Streamlit (até 20% EXTRA): Serão concedidos pontos extras aos grupos que programarem uma aplicação web via Streamlit² para visualização interativa dos dados modelados por meio das consultas produzidas.

OBSERVAÇÕES:

1. O trabalho deverá ser feito em **grupo de 3-4 alunos**.
2. O SGBD **SQLite** embarcado em um **Jupyter notebook** deverá ser utilizado para implementação do banco de dados e execução das consultas. **DICA:** Para acelerar a inserção de dados, desative temporariamente a validação de chaves estrangeiras (**PRAGMA foreign_keys = 0**).
3. A avaliação compreenderá o relatório (notebook) final entregue e a apresentação.

CALENDÁRIO:

12/06 (qui): Entrega da proposta (.pdf, máx. 1 página, via Moodle): definição do grupo (3-4 alunos) e do tema

A proposta deverá descrever o conjunto de dados escolhido do portal dados.gov.br/dados/conjuntos-dados. Para evitar temas duplicados, informe seu grupo e dataset escolhido na seguinte planilha: <https://bit.ly/43x3mSf>. Na proposta escrita (1 página), deverão ser listadas as entidades e relacionamentos presentes, o número de instâncias de cada entidade e relacionamento, e possíveis investigações (em alto nível) a serem formuladas sobre esses dados. A proposta deve ser submetida via Moodle.

26/06 (qui): Entrega do relatório final (.ipynb + .pdf, verifique o template no Moodle)

O relatório final deve ser feito no formato notebook (.ipynb), incluindo as seguintes seções (um template está disponível no Moodle): (1) Título; (2) Membros (nome e matrícula); (3) Descrição dos dados (como foram processados?); (4) Diagrama ER; (5) Diagrama relacional; (6) Consultas; (7) Autoavaliação dos membros.

Idealmente, o processamento dos dados deverá ser feito no próprio notebook e implementado na Seção 3.

Os diagramas ER e relacional produzidos deverão ser anexados nas Seções 4 e 5, respectivamente.

Na Seção 6, cada consulta deverá ser definida através de uma **explicação textual** e do respectivo **comando SQL**, acompanhado do **resultado da consulta**. **Gráficos também podem ser incluídos para melhor visualização** dos resultados.

Na Seção 7, a autoavaliação deverá descrever as atividades realizadas individualmente por cada membro.

26/06 e 01/07: Apresentações e submissões dos slides (enviado no Moodle até às 16hrs do dia da apresentação)

Cada grupo deverá preparar uma apresentação sucinta do trabalho realizado, incluindo uma descrição do tema, da modelagem desenvolvida (esquemas ER e relacional), e uma seleção das várias consultas formuladas (incluindo sua explicação em alto nível e seus resultados retornados). A apresentação deverá ter **no máx. 6 min**. Todos os membros do grupo deverão participar da apresentação, identificando-se e apresentando as partes que lhes couberam.

¹ Conjuntos de dados originalmente disponibilizados em formato SQL **não** poderão ser utilizados.

² <https://www.alura.com.br/artigos/streamlit-compartilhando-sua-aplicacao-de-dados-sem-dor-de-cabeca>